

Toxicity Analyzer

מערכת לניתוח תגובות YouTube וזיהוי רעילות באמצעות DistilBERT

toxic

severe_toxic

obscene

threat

insult

identity_hate

מקס — Frontend | נועם — Model + Backend | ענת — מצגת + הצגת המוצר

Pitch של 5 דקות: הבעיה, הפתרון, המימוש, התוצאה וההמשך

עולם הבעיה

?למה בכלל צריך את המוצר הזה

קהל יעד

מנהלי קהילות, יוצרי תוכן, חוקרי NLP ומשתמשים שרוצים להבין מה רמת הרעילות לפני גלישה.

הקושי

כמות התגובות עצומה, והשפה עצמה מורכבת: סלנג, רמיזות, העלבות עקיפות ואיומים מרומזים.

הבעיה

תגובות רעילות ברשת פוגעות בחוויית משתמש, מייצרות קהילות עוינות ומקשות על Moderation ידני.

השאלה שלנו: האם אפשר למדוד אוטומטית רעילות בתגובות, לפרק אותה ל-6 סוגים, ולהציג תמונה ברורה על סרטון או קהילה?

הפתרון שלנו

GUI ו-Data, AI מערכת אחת שמחברת בין

מה המשתמש מקבל

- אחוז רעילות כללי
- אחוז לכל label
- המלצה על רמת הסיכון
- טבלת תגובות עם הסיווגים

- או טקסט YouTube המשתמש מזין קישור לסרטון לבדיקה
- המערכת אוספת תגובות, מריצה אותן דרך מודל DistilBERT
- לכל תגובה מתקבלות 6 הסתברויות — אחת לכל קטגוריית רעילות
- בסוף מוצגים אחוזי רעילות כלליים ופירוק לפי סוג

YouTube Comments → DistilBERT → Prediction → Toxicity Dashboard

BERT למה בחרנו

הקשר חשוב יותר ממילים בודדות

מודלים קלאסיים

TF-IDF / XGBoost יודעים לזהות מילים, אבל פחות מבינים למי המשפט מופנה ומה המשמעות בתוך ההקשר.

DistilBERT


מבין סדר מילים, שלילה, ניסוחים עקיפים וקשרים סמנטיים. לכן הוא יכול להבדיל בין ביקורת על קוד לבין עלבון כלפי אדם.

"this code is stupid" ≠ "you are stupid"

ההבדל הוא Context — וזה בדיוק היתרון של BERT.

ארכיטקטורת המודל

ב-6 קטגוריות Multi-Label Classification



במקום תשובה אחת, כל תגובה מקבלת וקטור של 6 הסתברויות. לכן אותה תגובה יכולה להיות גם toxic וגם insult וגם threat בו־זמנית.

איך המודל לומד?

Training flow + Data Augmentation

דאטהסט

תגובות מסומנות עם וקטור labels.
לדוגמה: [1,0,0,1,1,0]

Loss

המודל משווה בין התחזית לאמת באמצעות
Binary Cross Entropy ומעדכן משקלים
ב־Backpropagation.

סה"כ: 159,572 דוגמאות | דוגמה: "you are stupid" → "honestly you are dumb right now"

המימוש בפועל

מה בנינו מקצה לקצה

Frontend

GUI שמקבל טקסט או קישור YouTube, מציג אחוזי רעילות, תוצאות לפי label וטבלת תגובות.

Backend

Flask/Python שמקבל בקשות, מושך תגובות דרך YouTube API ושולח אותן למודל.

Model Service

מודל DistilBERT מחזיר הסתברויות ל-6 labels, ואז מתבצע חישוב אחוזי toxicity לכל הסרטון.

הדגמה חיה: קישור סרטון → איסוף תגובות → ניתוח → Dashboard

מה הערך של המערכת

תוצאה ברורה, מהירה ושימושית

דוגמת פלט

Total comments 10,000

Toxicity rate 12.4%

insult 8.2%

threat 1.1%

identity_hate 0.7%

- מדידה אוטומטית של רמת הרעילות בערוץ או סרטון
- עזרה ליוצרי תוכן ולמנהלי קהילה לקבל החלטות בזמן אמת Moderation • בסיס למחקר על קהילות דיגיטליות ולראיונות GitHub Portfolio • פרויקט ברמה חזקה ל-

המערכת לא רק אומרת "כן/לא" — היא מסבירה איזה סוג רעילות קיים וכמה ממנו יש.

הצוות וחלוקת העבודה

איך עבדנו כקבוצה של 3

ענת

- מצגת + Demo
- בניית הסיפור להצגה
- ארגון ה-Pitch
- הצגת המוצר הסופי

נועם

- Model + Backend
- אימון DistilBERT
- לוגיקת הניתוח
- חיבור ל-Youtube API

מקס

- פיתוח ה-Frontend
- עיצוב ה-GUI
- חוויית משתמש
- חיבור הקלט והתצוגה

החלוקה אפשרה לנו לעבוד במקביל: UI, AI, והצגה — בלי להתנגש ועם אחריות ברורה לכל חלק.

המשך הדרך

מה היינו מוסיפים אם היה לנו עוד זמן

אתגרים אפשריים

איזון בין דיוק למהירות, מגבלות API, טעויות סיווג, ותגובות לא ברורות גם לבני אדם.

?איך נתגבר

עוד דאטה, הערכה טובה יותר, כיול threshold, ושילוב feedback ממשתמשים.

- סריקה של כתוביות הסרטון והצגת הסטטיסטיקה
- סריקה של ערוץ שלם ולא רק סרטון בודד
- השוואתי בין כמה סרטונים או קהילות Dashboard
- תמיכה בשפות נוספות מעבר לאנגלית
- dataset דינמי וכיול המודל לפי threshold • שיפור אמיתי
- live chat בזמן אמת ב-sarcasm, spam-toxicity • זיהוי chat

המטרה: להפוך את הפרויקט מכלי הדגמה למערכת Moderation שימושית באמת.